

# **FACULDADE DE TECNOLOGIA DE SÃO PAULO**

**CURSO SUPERIOR DE TECNOLOGIA EM DESENVOLVIMENTO DE  
SOFTWARE MULTIPLATAFORMA**

## **ANÁLISE DE ADEQUAÇÃO DE SOLO PARA CULTIVO DE MANDIOCA UTILIZANDO PERCEPTRON:**

**Uma Abordagem de Aprendizado de Máquina**

**Desenvolvido por:**

João Pedro Dias Barreto  
Leonardo Wicher Lopes Ferreira

Relatório Técnico - Projeto de Aprendizado de Máquina

São Paulo  
December de 2025

# RESUMO

Este trabalho apresenta o desenvolvimento e implementação de um modelo de Perceptron para classificação binária da adequação de solo para o cultivo de mandioca (*Manihot esculenta*). O sistema desenvolvido analisa quatro parâmetros edáficos fundamentais: pH do solo, concentração de potássio, qualidade da drenagem e presença de compactação. O modelo alcançou  $97,78\% \pm 4,44\%$  de acurácia na validação cruzada, demonstrando alta eficácia na predição da adequação do solo. A implementação inclui uma interface gráfica intuitiva para aplicação prática por agricultores e técnicos agrícolas.

**Palavras-chave:** Perceptron, Agricultura de Precisão, Classificação de Solo, Aprendizado de Máquina, Mandioca.

## 1. INTRODUÇÃO

A mandioca (*Manihot esculenta*) constitui uma das principais culturas alimentares do mundo, sendo especialmente relevante para a segurança alimentar em países tropicais. No Brasil, representa importante fonte de carboidratos e matéria-prima para diversos produtos industriais.

A adequação do solo representa fator determinante para o sucesso do cultivo da mandioca, influenciando diretamente na produtividade e qualidade das raízes tuberosas. Fatores como pH, disponibilidade de nutrientes, drenagem e estrutura física do solo são parâmetros críticos que determinam a viabilidade econômica do cultivo.

Tradicionalmente, a avaliação da adequação do solo baseia-se na experiência empírica dos produtores ou em análises laboratoriais interpretadas por técnicos especializados. Esta abordagem apresenta limitações relacionadas à subjetividade da interpretação, custos elevados e tempo prolongado para obtenção de resultados.

Neste contexto, técnicas de aprendizado de máquina emergem como ferramentas promissoras para automatização e otimização da tomada de decisão na agricultura de precisão.

## 2. METODOLOGIA

### 2.1 Descrição do Modelo

O modelo implementado baseia-se na arquitetura clássica do Perceptron monocamada, com as seguintes características:

- Arquitetura: 4 neurônios de entrada correspondentes aos atributos de entrada
- Função de ativação: Degrau unitário (step function)
- Saída: Classificação binária (0 = não apto, 1 = apto)

### 2.2 Função de Ativação

A função de ativação degrau foi implementada conforme:

$$f(x) = 1, \text{ se } x \geq 0$$

$$f(x) = 0, \text{ se } x < 0$$

Onde  $x$  representa a soma ponderada das entradas mais o bias.

### 2.3 Algoritmo de Treinamento

O treinamento utiliza a regra Delta:  $\Delta w_i = \eta \times e \times x_i$

Onde  $\eta$  = taxa de aprendizado,  $e$  = erro (saída desejada - saída obtida),  $x_i$  = entrada  $i$

### 2.4 Base de Dados

O dataset foi construído com base em conhecimento agronômico estabelecido, contendo 45 exemplos balanceados com os seguintes atributos:

- pH do solo (4,0 - 8,0)
- Potássio em  $\text{mg/dm}^3$  (40 - 200)
- Drenagem (0=ruim, 1=boa)
- Compactação (0=presente, 1=ausente)
- Classe alvo: Adequado (0=não, 1=sim)

#### Distribuição das classes:

- Solos adequados: 22 exemplos (48,9%)
- Solos inadequados: 23 exemplos (51,1%)

### 3. RESULTADOS E DISCUSSÃO

Tabela 1 - Resultados da validação cruzada 5-fold

Métrica	Valor
Acurácia Média	97,78% ± 4,44%
Épocas Médias	4,2 ± 1,1
Melhor Fold	100,00%
Pior Fold	88,89%

Tabela 2 - Impacto da taxa de aprendizado na performance

Taxa ( $\eta$ )	Acurácia (%)	Épocas	Observações
0,01	93,33 ± 5,44	24,3 ± 6,2	Convergência lenta
0,05	95,56 ± 3,14	17,0 ± 12,0	Moderada
0,10	95,56 ± 6,29	5,3 ± 1,2	Balanceada
0,20	97,78 ± 3,14	8,7 ± 0,9	Ótima
0,50	100,00 ± 0,00	5,3 ± 1,2	Excelente

Tabela 3 - Importância dos fatores (pesos absolutos médios)

Fator	Peso Médio	Importância
Distância do pH Ideal	0,40	Crítica
Ausência de Compactação	0,31	Alta
Boa Drenagem	0,11	Média
Potássio Normalizado	0,07	Baixa

## 4. DISCUSSÃO CRÍTICA

### 4.1 Vantagens do Modelo

- **Alta Interpretabilidade:** O Perceptron permite compreensão direta da importância de cada fator através dos pesos sinápticos, facilitando a validação agrônômica dos resultados.
- **Simplicidade Computacional:** A implementação requer recursos computacionais mínimos, viabilizando aplicação em dispositivos móveis e sistemas embarcados.
- **Convergência Rápida:** O modelo converge em média após 4,2 épocas, demonstrando eficiência no aprendizado dos padrões.
- **Performance Robusta:** Acurácia de 97,78% indica alta confiabilidade para aplicação prática.

### 4.2 Limitações Identificadas

- **Linearidade dos Dados:** O Perceptron assume separabilidade linear das classes, limitando sua aplicação a problemas linearmente separáveis.
- **Tamanho da Base de Dados:** Dataset com 45 exemplos pode ser insuficiente para capturar toda a variabilidade das condições de campo.
- **Fatores Não Considerados:** Importantes parâmetros como matéria orgânica, micronutrientes e aspectos climáticos não foram incluídos no modelo.

### 4.3 Regras de Decisão Interpretáveis

#### **Solo ADEQUADO quando:**

- pH próximo a 6,0 ( $\pm 0,5$ )
- Solo não compactado
- Drenagem adequada
- Potássio > 100 mg/dm<sup>3</sup>

#### **Solo INADEQUADO quando:**

- pH < 5,0 ou pH > 7,0
- Presença de compactação
- Drenagem deficiente
- Combinação de múltiplos fatores limitantes

## 5. CONCLUSÃO

O presente trabalho demonstrou a viabilidade e eficácia da aplicação do algoritmo Perceptron para classificação da adequação de solo para cultivo de mandioca. O modelo desenvolvido alcançou performance excepcional (97,78% de acurácia), convergência rápida e alta interpretabilidade dos resultados.

A análise dos pesos sinápticos confirmou conhecimentos agronômicos estabelecidos, identificando o pH como fator mais crítico, seguido pela ausência de compactação do solo. Esta concordância entre os resultados do modelo e o conhecimento técnico valida a abordagem metodológica adotada.

A interface gráfica desenvolvida viabiliza a aplicação prática do sistema, democratizando o acesso à tecnologia de suporte à decisão na agricultura. O sistema pode contribuir significativamente para otimização do uso da terra, redução de custos de análise e melhoria da produtividade agrícola.

O trabalho contribui para o avanço da agricultura de precisão no Brasil, demonstrando que técnicas simples de aprendizado de máquina podem gerar impacto significativo quando aplicadas adequadamente a problemas agronômicos específicos.

## REFERÊNCIAS

COCK, J. H. **Cassava: new potential for a neglected crop**. Boulder: Westview Press, 1985. 191 p.

EL-SHARKAWY, M. A. Cassava biology and physiology. **Plant Molecular Biology**, v. 56, n. 4, p. 481-501, 2003.

FAO - FOOD AND AGRICULTURE ORGANIZATION. **FAOSTAT - Crops and livestock products**. Roma: FAO, 2021.

IBGE - INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. **Levantamento sistemático da produção agrícola**. Rio de Janeiro: IBGE, 2022. 85 p.

KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. **Proceedings of the 14th International Joint Conference on Artificial Intelligence**, v. 2, p. 1137-1143, 1995.

ROSENBLATT, F. The perceptron: a probabilistic model for information storage and organization in the brain. **Psychological Review**, v. 65, n. 6, p. 386-408, 1958.